

Dokumentasi Algoritma & Pemetaan Kode Program

Penelitian: Modifikasi Zero-DCE Berbasis CBAM untuk Enhancement Citra Low-Light CCTV Inframerah Pada Kandang Burung Walet

Dokumen ini menjelaskan secara teknis dan matematis alur arsitektur *deep learning* yang digunakan dalam penelitian ini (Zero-DCE dan Modifikasi CBAM berbasis *Darkness Map*), beserta pemetaan presisi lokasi baris kode di dalam struktur *project*.

1. Diagram Alur Arsitektur Algoritma Zero-DCE + CBAM

Berikut adalah rancangan alur arsitektur jaringan *deep learning* yang digunakan:



2. Algoritma Zero-DCE Baseline (Skenario B)

Zero-Reference Deep Curve Estimation (Zero-DCE) adalah metode peningkatan kualitas citra pencahayaan rendah tanpa memerlukan *paired ground-truth* (pasangan foto terang-gelap).

A. DCE-Net (Feature Extractor & Parameter Estimator)

DCE-Net menggunakan 7 layer konvolusi simetris dengan *skip connections* untuk mengestimasi peta parameter kurva $A(x)$.

- **Formulasi Output Layer:**

$$A(x) = \tanh(\text{Conv}_7(\text{Concat}(x_1, x_6)))$$

Aktivasi tanh membatasi parameter kurva $A(x)$ di rentang $[-1.0, 1.0]$.

- **Dimensi Output:** $[B, 24, H, W]$ di mana $24 = 8 \text{ iterasi} \times 3 \text{ channel RGB}$.

B. Iterative Quadratic Enhancement Curve

Fungsi peningkat kecerahan citra secara bertahap menggunakan kurva kuadratik:

$$E_0(x) = I(x)$$

$$E_n(x) = E_{n-1}(x) + A_n(x) \cdot E_{n-1}(x) \cdot (1 - E_{n-1}(x)) \text{ (untuk } n = 1, 2, \dots, 8)$$

3. Algoritma Modifikasi CBAM Berbasis Darkness Map (Skenario C)

CBAM (*Convolutional Block Attention Module*) dimodifikasi dengan memasukkan informasi tingkat kegelapan (*Darkness Map*) $D(x) = 1 - I(x)$ agar model memfokuskan perhatian secara spesifik pada area gelap kandang walet.

A. Darkness Map Extractor

Mengekstrak peta tingkat kegelapan lokal dari citra input:

$$D(x) = 1.0 - \text{Mean}_{\text{channel}}(I(x))$$

Nilai $D(x) \in [0.0, 1.0]$, di mana 1.0 merepresentasikan piksel sangat gelap dan 0.0 merepresentasikan piksel terang.

B. Dark-Aware Channel Attention Module

Memperhitungkan bobot channel dengan menggabungkan Max Pooling dan Average Pooling yang dibobot secara khusus oleh $D(x)$:

1. **Pooling Berbobot Kegelapan:**

$$AvgPool_{dark} = \Sigma[F(x) \cdot D(x)] / (\Sigma D(x) + \epsilon)$$

$$MaxPool_{dark} = \max[F(x) \cdot D(x)]$$

2. Shared MLP Layer (1×1 Conv):

$$MLP(v) = Conv_{1 \times 1}^{(2)}(ReLU(Conv_{1 \times 1}^{(1)}(v)))$$

3. Channel Attention Map M_{c_dark} :

$$M_{c_dark} = \sigma(MLP(AvgPool_{dark}) + MLP(MaxPool_{dark}))$$

4. Channel-refined Feature F_c :

$$F_c = M_{c_dark} \otimes F$$

C. Dark-Guided Spatial Attention Module

Menggabungkan Max Pooling dan Average Pooling sepanjang *channel axis*, diproses via Konvolusi 7×7, dan dipandu secara langsung oleh $D(x)$:

1. Pooling Spasial: $[AvgPool_c(F_c), MaxPool_c(F_c)]$ sepanjang channel axis.

2. Spatial Attention Map M_{s_dark} :

$$M_{s_dark} = \sigma(Conv_{7 \times 7}([AvgPool_c(F_c), MaxPool_c(F_c)])) \odot D(x)$$

3. Residual Gating Refinement (F_{cs}):

$$F_{cs} = F_c \otimes (1.0 + M_{s_dark})$$

Catatan Formulasi: Penggunaan residual gating ($1.0 + M_{s_dark}$) memastikan attention menguatkan fitur pada area gelap tanpa mematikan fitur pada area yang sudah cukup terang.

4. Fungsi Kerugian (Non-Reference Loss Functions)

Pelatihan dilakukan tanpa citra referensi (*zero-reference*) menggunakan kombinasi 4 fungsi kerugian:

$$L_{total} = \lambda_{spa} L_{spa} + \lambda_{exp} L_{exp} + \lambda_{col} L_{col} + \lambda_{tvA} L_{tvA}$$

- **Spatial Consistency Loss (L_{spa}):** Mempertahankan kontras lokal 4-arah (kiri, kanan, atas, bawah) antara citra input dan output.
- **Exposure Control Loss (L_{exp}):** Mengukur jarak kuadrat daerah lokal patch 16×16 terhadap nilai paparan target ($E = 0.55$). Pada Skenario C, dilengkapi *Adaptive Pixel-Wise Dark Weighting* berbasis $D(x)^Y$.
- **Color Constancy Loss (L_{col}):** Berdasarkan prinsip Gray-World untuk mencegah pergeseran warna yang tidak alami.

- **Illumination Smoothness Loss (L_{tvA}):** Menjaga kehalusan gradien spasial pada peta kurva $A(x)$ menggunakan Total Variation (TV) loss.

5. Pemetaan Lokasi Algoritma dalam File Program

Berikut adalah tabel pemetaan lengkap lokasi algoritma dan fungsi matematika dalam file kode Python (diperbarui sesuai struktur repository):

Komponen Algoritma	Nama File Kode	Nama Class / Fungsi	Nomor Baris Kode
DCE-Net Architecture	enhancement/models/zero_dce.py	DCENet	Baris 14 – 48
Zero-DCE Enhancement Curve	enhancement/models/zero_dce.py	ZeroDCE.enhance_curve()	Baris 60 – 79
Darkness Map Calculation	enhancement/models/dark_attention.py	compute_darkness_map()	Baris 17 – 36
Channel Attention Module	enhancement/models/dark_attention.py	DarkAwareChannelAttention	Baris 39 – 84
Spatial Attention Module	enhancement/models/dark_attention.py	DarkGuidedSpatialAttention	Baris 87 – 127
Modul CBAM Lengkap	enhancement/models/dark_attention.py	DarkCBAMModule	Baris 130 – 148
Integrasi Zero-DCE + CBAM	enhancement/models/zero_dce_cbam.py	ZeroDCE_CBAM	Baris 20 – 94
Adaptive Curve Estimation Head	enhancement/models/zero_dce_cbam.py	ZeroDCE_CBAM.forward()	Baris 84
Spatial Consistency Loss (L_{spa})	enhancement/losses/spatial_consistency.py	SpatialConsistencyLoss	Baris 12 – 53
Exposure Control Loss (L_{exp})	enhancement/losses/exposure_control.py	ExposureControlLoss	Baris 11 – 37
Color Constancy Loss (L_{col})	enhancement/losses/color_constancy.py	ColorConstancyLoss	Baris 11 – 28
Illumination Smoothness Loss (L_{tvA})	enhancement/losses/illumination_smoothness.py	IlluminationSmoothnessLoss	Baris 11 – 30

Komponen Algoritma	Nama File Kode	Nama Class / Fungsi	Nomor Baris Kode
Total Non-Reference Loss	enhancement/losses/__init__.py	ZeroDCELoss	Baris 15 – 72
Training Pipeline Zero-DCE	enhancement/train_zero_dce.py	train_zero_dce()	Baris 86 – 230
Training Pipeline Zero-DCE+CBAM	enhancement/train_zero_dce_cbam.py	train_zero_dce_cbam()	Baris 97 – 244
Batch Enhancement Generator	enhancement/enhance.py	enhance_dataset()	Baris 31 – 122
3-Panel & 6-Panel Evaluator	enhancement/evaluate_enhancement.py	evaluate_enhancement()	Baris 168 – 266